

Machine Learning I

Avaliação e Adaptação de Algoritmos de Classificação

Equipa de Desenvolvimento

202300276 – Guilherme Klippel

202304280 – Daniel Tiago

202512256 – Lucas Coelho

Universidade do Porto (U. PORTO)

Turma: PL3 | Grupo: PL3_G1

Docente: Rita Paula Almeida Ribeiro

1. Objetivo

- Implementar algoritmos de classificação de raiz para uma compreensão aprofundada do seu funcionamento teórico e empírico.
- Analisar o impacto do desbalanceamento de dados no modelo e desenvolver uma proposta original para mitigar esse problema.

2. Resumo da Nossa Abordagem

- Fase 1: Implementação do pré-processamento para Logistic Regression e identificação das suas limitações estruturais em problemas multiclasse.
- Fase 2: Extensão do algoritmo para Softmax Regression, permitindo o suporte nativo a K classes.
- Fase 3: Introdução da proposta original Weighted Softmax, que aplica pesos individuais a cada classe para lidar com dados desbalanceados.

3. Regressão Logística

- **O que é:** Um modelo de classificação binária que estima a probabilidade (de 0 a 1) de um dado pertencer a uma categoria. A decisão final é feita aplicando um limiar de corte sobre esse valor, utilizando esta fórmula:

$$P = \frac{1}{1 + e^{-z}}$$

- **Vantagens:**

- Simplicidade: Rápido de treinar e computacionalmente leve.
- Interpretabilidade: Não dá apenas a decisão, dá a probabilidade.


- **Desvantagens:**

- Limitação Binária: Na sua origem, não suporta múltiplas classes (motivação para usarmos Softmax).
- Sensibilidade: Lida mal com dados desbalanceados.

4. Pré-Processamento e Pipeline de Dados

- ▼ **Imputação de Valores Nulos:** Substituição por mediana para dados numéricos (robustez a outliers) e moda para categóricos.
- 🔗 **One-Hot Encoding:** Conversão de variáveis qualitativas em binárias, com remoção da primeira coluna para evitar colinearidade.
- ↔ **Normalização Z-Score:** Padronização das escalas para média 0 e desvio padrão 1, garantindo peso igual para todas as features.
- 🛡 **Prevenção de Data Leakage:** Parâmetros estatísticos de escala calculados exclusivamente no conjunto de treino.
- 🔒 **Validação Robusta:** Implementação de K-Fold Cross-Validation com 5 folds para garantir a generalização dos resultados.

5. Resultados iniciais em todos os benchmarkings



Como a regressão logística lida mal com datasets multiclasse, decidimos focar a nossa solução nesse problema.

6. Regressão Logística Softmax

- **O que é:** É a versão multiclasse da regressão logística. O modelo calcula um score bruto (z) para cada categoria e o converte em probabilidade usando a fórmula:

$$P(i) = \frac{e^{z_i}}{\sum_{j=1}^n e^{z_j}}$$

- **Vantagens:**


- Multiclasse: Classifica várias categorias de uma só vez.
- Transparência: Mostra a porcentagem de confiança para cada categoria.

- **Desvantagens:**

- Exclusivo: O dado só pode pertencer a uma única classe (não serve para multirrótulo).
- Sensível: Pode dar erro matemático com números muito grandes e sofre com dados desbalanceados.

7. Resultados Regressão Logística vs Softmax

Em datasets multiclasse



Os gráficos apresentados evidenciam um desempenho superior do algoritmo Softmax, conclusão que pode ser estatisticamente validada por meio do teste de hipóteses.

8. Teste de Hipóteses Wilcoxon Signed-Rank


Formulação das hipóteses

- H_0 : Logistic e Softmax têm performance equivalente.
- H_1 : Logistic e Softmax têm performance diferente.
- Nível de significância: $\alpha = 0.05$.

Decisão:

- $p\text{-value} < 0.05 \rightarrow$ rejeitamos $H_0 \rightarrow$ diferença estatisticamente significativa.
- $p\text{-value} \geq 0.05 \rightarrow$ não rejeitamos $H_0 \rightarrow$ não há evidência de diferença.

Aplicamos o teste a cada uma das 4 métricas (Accuracy, Precision, Recall, F1).



Os quatro p-values obtidos situam-se na ordem de 10^{-8} , valores várias ordens de grandeza inferiores ao nível de significância estabelecidos ($\alpha = 0.05$). Rejeitamos portanto H_0 em todas as métricas testadas.

9. Observação

Métrica	Softmax
Accuracy	0.7449
Precision (macro)	0.6411
Recall (macro)	0.6327
F1-Score (macro)	0.6202
Gap Acc – F1	0.1247

Resultado do Softmax padrão

A Accuracy ultrapassa o F1 macro em cerca de 0.12 pontos. Esta diferença é a assinatura clássica de desbalanceamento de classes: o modelo acumula acerto global nas classes majoritárias, enquanto o F1 macro — que pondera todas as classes equitativamente — revela que as minoritárias estão a ser sub-aprendidas.

Decidimos, portanto, testar uma variante do Softmax, o Softmax **Weighted** , para ver se conseguimos melhorar ainda mais os resultados do dataset multiclasse.


10. Softmax Weighted

- **O que é:** É uma variante do Softmax projetada para lidar com datasets desbalanceados. O modelo atribui um "peso de importância" para cada classe, sendo inversamente proporcional à sua frequência. Isso força o algoritmo a penalizar mais fortemente os erros cometidos nas classes mais raras. O peso é calculado pela fórmula:

$$w_c = \frac{N}{K \times n_c}$$

- **Vantagens:**
 - Equilíbrio: Resolve o principal ponto fraco do Softmax tradicional, impedindo que o modelo ignore as classes minoritárias.
 - Maior Sensibilidade: Melhora drasticamente métricas como Recall Macro, tornando o modelo excelente para identificar eventos raros.
- **Desvantagens:**
 - Risco de Overfitting: Dar um peso gigantesco para uma classe minúscula pode fazer o modelo "decorar" ruídos dos dados em vez de aprender o padrão real.
 - Exclusivo: Assim como o Softmax padrão, continua servindo apenas para problemas onde o dado pertence a uma única classe.

11. Resultados Softmax Weighted vs Softmax Padrão



Embora o Softmax Padrão apresente um resultado geral maior, o Softmax Weighted cumpriu o seu papel: aumentou a importância das classes menos frequentes e, conseqüentemente, elevou o Recall. O próximo passo é realizar um teste de hipótese para verificar se essa mudança possui validade estatística.

12. Teste de Hipóteses Wilcoxon Signed-Rank

Formulação das hipóteses


- H_0 : Weighted Softmax e Softmax têm performance equivalente.
- H_1 : Weighted Softmax e Softmax têm performance diferente.
- Nível de significância: $\alpha = 0.05$.

Decisão:

- $p\text{-value} < 0.05 \rightarrow$ rejeitamos $H_0 \rightarrow$ diferença estatisticamente significativa.
- $p\text{-value} \geq 0.05 \rightarrow$ não rejeitamos $H_0 \rightarrow$ não há evidência de diferença.

Aplicamos o teste a cada uma das 4 métricas, adotando F1 macro como métrica primária


Quanto ao efeito líquido em F1 macro, este é praticamente nulo($\Delta = -0.005$, $p = 0.10$). Como F1 é a média harmónica de precision e recall, e estes movem-se em direcções opostas com magnitudes semelhantes, o resultado é neutro: não rejeitamos H_0 para a métrica primária. Mantemos o Softmax Padrão como a melhor escolha pro dataset multiclases.




13. Estudo de caso Weighted Softmax

Decidimos mostrar os resultados do Weighted Softmax vs Softmax em um exemplo de dataset desbalanceado dentro do multiclasse.


Distribuição de Classes - Dataset Page-Blocks



O Extremo Trade-off: Softmax Baseline vs Weighted Softmax



Dinâmica de Pesos: Como o Modelo Compensa o Desbalanceamento



- O Softmax baseline alcança 93.52% de Accuracy — mas o Recall macro de apenas 45.11% revela que essa "boa" performance vem de acertar quase tudo na classe majoritária, ignorando grande parte das classes restantes.
- O Weighted Softmax inverte este comportamento: o Recall macro sobe para 80.97% (+35.86 pontos!), demonstrando que o modelo passa a identificar exemplos das classes raras. O preço é uma quebra em Accuracy e Precision, sinal de que o modelo agora arrisca mais palpites nas classes minoritárias.

14. Conclusão

Análise dos Resultados:

- **A Superioridade da Abordagem Softmax:** Em problemas nativamente multiclasse, o modelo Softmax demonstrou ser estatisticamente superior à Regressão Logística padrão.
- **O Trade-off Inerente ao Balanceamento:** A introdução do Weighted Softmax revelou a dinâmica clássica de custo-benefício (trade-off) em Machine Learning.

Concluímos que a escolha entre Softmax e Weighted Softmax não é uma questão de qual modelo é "melhor" de forma absoluta, mas sim de alinhamento com o objetivo do problema.

Melhoras Futuras:

- **Suavização dos Pesos:** Testar fórmulas matemáticas menos agressivas na hora de calcular os pesos, buscando aumentar o Recall das classes raras sem sacrificar tanta Accuracy e Precisão.
- **Técnicas de Geração de Dados:** Em vez de mexer apenas no algoritmo, testar o uso de métodos como SMOTE para criar dados artificiais e equilibrar o dataset antes do treino.